CC0F4 EXAMEN PARCIAL

Recuperación, RAG y una herramienta con contratos sobre el Código Civil peruano

Carlos Sinai Unda Miguel

Continuación de la PC1 y la PC2: detección de contradicciones normativas. Repositorio con la etiqueta examen-parcial.

Corpus y evaluación

2115

artículos vigentes indexados

20

consultas, 31 pares relevantes

12

preguntas para RAG, 2 sin evidencia

13

casos de la herramienta

PROBLEMA Y CONTINUIDAD

Antes de detectar contradicciones hay que encontrar las normas

PC1

Clasificador con Qwen2.5-0.5B sobre pares ya emparejados.

El par llegaba hecho a mano; 9 casos sintéticos.

PC2

Recuperación densa E5 + FAISS con consulta estructurada.

10 documentos sintéticos; 4 de 6 JSON inválidos por una tilde.

Parcial

Recuperación A/B/C, RAG con citas auditado a mano y una herramienta de plazos.

Código Civil real (D.L. 295), qrels anotados antes de comparar.

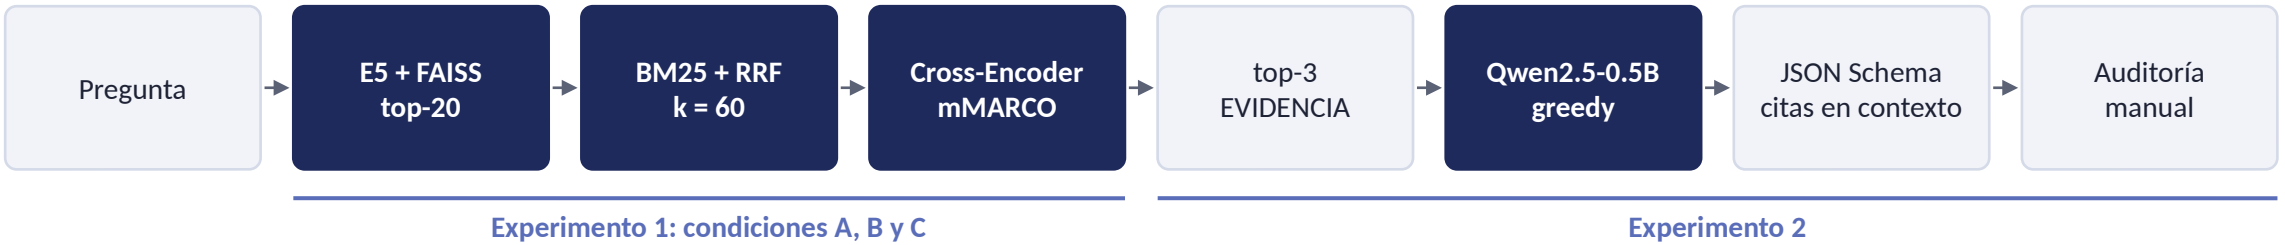
Observación de la PC2: por qué una tilde impide toda la búsqueda

`"prohibición_permiso"`
`"prohibicion_permiso"`
ó es U+00F3 y o es U+006F: el enum del JSON Schema compara cadenas exactas.

- Un carácter invalida el objeto, la consulta estructurada no pasa la validación y la búsqueda no se ejecuta.
- En el parcial se busca con la pregunta original y la salida no tiene enums de texto: citas con patrón cc_art_N y abstención booleana.

ARQUITECTURA Y DATOS

Tres condiciones de recuperación y un generador que debe citar



Corpus

- Código Civil peruano, 2135 artículos; se indexan los 2115 vigentes
- Un artículo por passage (cc_art_183): es la unidad que se cita
- Media 43 palabras; 4 artículos pasan de 512 tokens, ninguno relevante
- 7 artículos con texto dudoso, fuera de los qrels

Consultas y qrels

Tipo	n	Prueba
directa	12	vocabulario del Código
parafraseada	5	lenguaje cotidiano
contradicción	3	regla y excepción

31 pares relevantes con el inciso que los justifica, fijados antes de ejecutar. Ejemplo C05: arts. 183 y 2007.

Herramienta (sin LLM)

- plazos.computar_vencimiento: arts. 183 y 2007
- Contrato de entrada, dominio, salida
- ToolResult o ToolError con kind y retryable
- Calendario 2026 con 16 feriados nacionales

TRAZABILIDAD

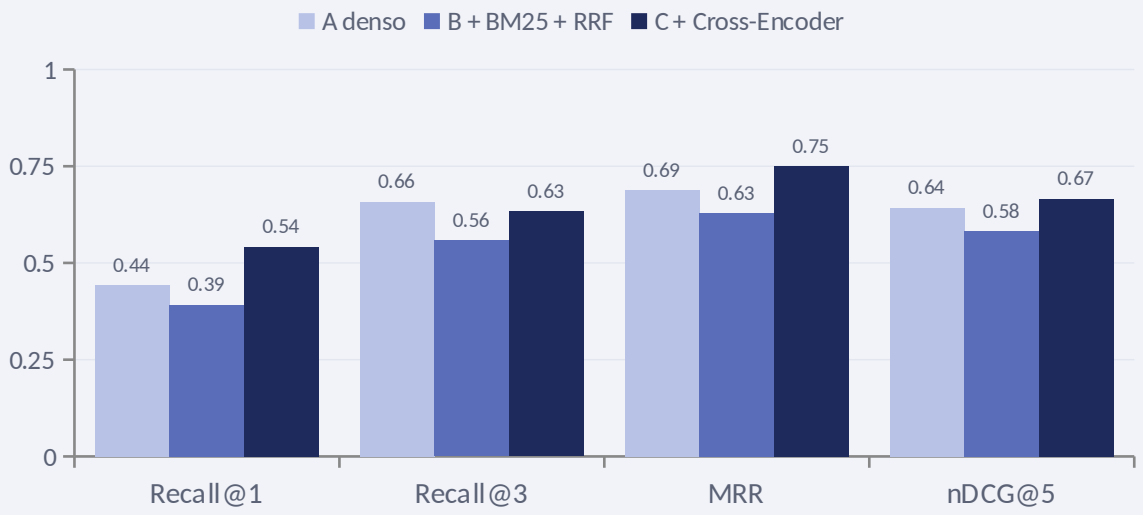
Cada semana deja una evidencia en el repositorio

Sem.	Recurso	Concepto	Evidencia verificable	Conclusión propia
1	Cuaderno 1, Lectura 2	tokens, Q/K/V, máscara causal	Qwen: 24 capas, 14 cabezas Q y 2 KV; "caducidad" = cad + uc + idad	Evidencia antes de la pregunta en el prompt
2	Cuaderno 2, Laboratorio 2, Lectura 3	logits, softmax, greedy	P(primer token {") 0.921 sin evidencia y 0.763 con evidencia; 179 frente a 602 tokens	El costo del RAG está en el prefill
3	Cuaderno 3	JSON Schema, validación	Schema 8/12 closed-book y 12/12 RAG	Válido no significa correcto
4	Cuaderno 4, Laboratorio 4	E5, coseno, FAISS, qrels	Score FAISS = coseno a mano (0.9346); A: Recall@3 0.658	Línea base de la PC2
5	Cuaderno 5, Lectura 5	BM25, RRF, Cross-Encoder	C13: BM25 sube los arts. 2081 y 2082 y el 333 cae al puesto 13	La fusión trae distractores léxicos
6	Cuaderno 6, Lectura 6	contratos, retry, timeout	13/13 casos; H09 se recupera en el intento 2	Solo se reintenta lo transitorio
7	Cuaderno 7, Lectura 7	MRR, nDCG, bootstrap, faithfulness	C - B nDCG@5 +0.084 [0.001, 0.179]; faithfulness RAG 0.25	Mejor ranking no es mejor respuesta

EXPERIMENTO 1

BM25 + RRF no mejora; el reranker ordena mejor, pero cuesta 3 s

Métricas por condición (20 consultas)



Bootstrap pareado y latencia

Diferencia	Media	IC 95 %
B - A Recall@3	-0.100	[-0.225, 0.000]
B - A nDCG@5	-0.060	[-0.131, 0.009]
C - B MRR	+0.121	[-0.007, 0.261]
C - B nDCG@5	**+0.084**	**[0.001, 0.179]**

Latencia media: A 60 ms, B 52 ms, C 3123 ms.
El Cross-Encoder es el 98 % del costo de C.

Error analizado: C13, separación de hecho

El art. 333 está en el puesto 3 en A. En B cae al 13: BM25 premia los arts. 2081 y 2082 de Derecho Internacional Privado, que repiten "divorcio y separación de cuerpos" pero regulan la ley aplicable. C lo devuelve al puesto 3. C07, C12 y C19 (parafraseadas) no tienen ningún relevante entre los 20 candidatos en ninguna condición.

EXPERIMENTO 2

La evidencia llega al contexto, pero el modelo de 0.5B no la usa

Closed-book frente a RAG (top-3 de C)

Medida	Closed-book	RAG
Cumple el schema	8 / 12	12 / 12
Correctas (10 consultas)	**2 / 10**	**1.5 / 10**
Cita algún artículo	0 / 10	0 / 10
Afirmaciones respaldadas	0 / 12	3 / 12
Abstención sin evidencia	0 / 2	1 / 2
Latencia media	14.9 s	34.5 s

Evidencia completa en el contexto en 7 de 10 consultas. Auditoría manual por afirmación: respaldada solo si un artículo entregado la dice explícitamente.

Qwen2.5-0.5B-Instruct, greedy, 220 tokens, mismo prompt de sistema.

C06, respuesta no sustentada

El art. 2001 llegó primero: "a los diez años, la acción … de nulidad". El RAG respondió "tres" (inciso 3, otra acción). Closed-book había dicho 10.

C05, regla frente a excepción

Con los arts. 2007 y 183 en el contexto, respondió que la caducidad sí se traslada al día hábil: aplicó la regla general.

N01, sin evidencia en el Código

El art. 648 dice "el plazo para apelar es de cinco días" para el consejo de familia. Respondió "cinco días" en vez de abstenerse.

EXPERIMENTO 3

Cómputo de plazos: el contrato decide qué se reintenta

Caso	Entrada o fallo	Resultado	Intentos
H01	30 días desde el 1/10	ok: 2/11 (sábado y feriado trasladados)	1
H03	H01 como caducidad	ok: 31/10, sin traslado (art. 2007)	1
H05	cantidad = -5	validation	0
H08	vence en 2027	domain: fuera_de_calendario	1
H09	fallo transitorio una vez	ok en el intento 2 (59.9 ms)	2
H10	fallo transitorio persistente	transient, reintentos agotados	3
H11	fuente lenta 500 ms	timeout, 753 ms en total	3
H12	salida corrupta	output_contract	1
H13	herramienta no permitida	protocol	0

13 de 13 casos con el resultado esperado; las fechas se calcularon a mano antes de ejecutar. 20 pruebas de pytest pasan.

Política

- Hasta 3 intentos, espera de 50 y 100 ms
- 200 ms por intento, 800 ms de límite total
- Antes de esperar se verifica el tiempo restante

Por qué reintentar solo transient y timeout

La fuente del calendario puede responder en el siguiente intento. Con validation, domain o protocol los mismos argumentos dan el mismo error. output_contract es un defecto de la implementación: reintentarlo lo ocultaría.

Bajo este corpus, el cuello de botella es el generador

Exp.	Línea base	Modificación	Resultado principal	Error representativo
1	A denso	B: + BM25 + RRF; C: + Cross-Encoder	C mejora nDCG@5 en +0.084 frente a B; A tiene el mejor Recall@3 (0.658)	C13: distractor léxico de DIP
2	closed-book	top-3 de C en el prompt	Correctas 1.5 frente a 2 de 10; 0 citas; 3 de 12 respaldadas	C06: "tres" con el art. 2001 primero
3	13 casos esperados	fallos inyectados	13 de 13; reintento solo en transient y timeout	H08: vencimiento fuera del calendario

Limitaciones

- 20 consultas y qrels del autor, sin validación externa
- Una sola norma extraída de PDF; 4 artículos truncados
- Generador de 0.5B en CPU; auditoría de una sola persona
- Fallas de la herramienta simuladas; calendario de un año

Conclusión

La recuperación densa trae el artículo correcto en la mayoría de las consultas directas y el reranker lo ordena mejor. Con Qwen2.5-0.5B, recibir la evidencia no mejoró la respuesta ni produjo citas. Antes de la etapa de agentes conviene cambiar el generador, no el recuperador.