CC0F4 · SEGUNDA PRÁCTICA CALIFICADA

Recuperación densa de normas candidatas a contradicción

Carlos Sinai Unda Miguel

Continuación de la PC1: antes de clasificar un par de normas con NLI, hay que encontrar la Norma B. Consulta estructurada con un LLM, embeddings E5 y FAISS, evaluados con Recall@k.

Flujo mínimo

1. Necesidad de información
2. Qwen2.5-0.5B → JSON
3. JSON Schema
4. query: + E5 → FAISS
5. top-k → Recall@k

PROBLEMA

Antes del NLI hay que encontrar la Norma B

PC1

Recibía el par (Norma A, Norma B) ya emparejado y solo clasificaba su relación.

PC2

Dada una necesidad de información, recuperar los fragmentos que regulan el mismo supuesto: los dos lados de una posible contradicción.

Ejemplo N3

"Me notificaron una resolución y quiero apelarla, ¿cuántos días tengo para presentar la apelación?"

Norma A · D05 art. 6

El plazo para interponer recurso de apelación es de quince días hábiles.

Norma B · D06 art. 7

El recurso de apelación debe interponerse dentro de los cinco días hábiles siguientes a la notificación.

10

documentos sintéticos

76

passages (artículos)

6

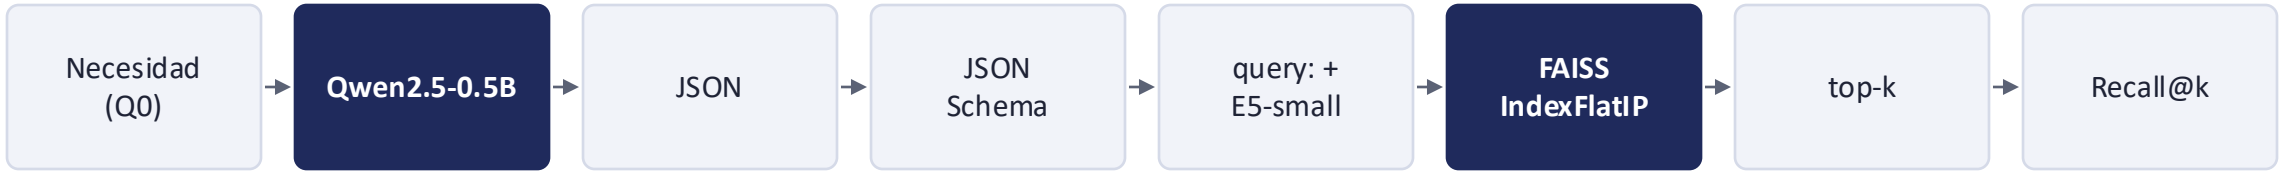
necesidades (casos 1-6 de la PC1)

12

evidencias, 2 por consulta

PIPELINE

Consulta estructurada → embeddings → FAISS



Semana 3 · generación estructurada y validación

Semana 4 · embeddings y recuperación densa

Salida esperada por el schema

```
{"query": "plazo para interponer
recurso de apelación",
 "intent": "plazo",
 "abstain": false}
```

- intent: plazo · prohibicion_permiso · vigencia · obligacion · derecho
- additionalProperties: false

Tres niveles de validez

1. **Parseable**
   se puede extraer un objeto JSON
2. **Schema-valid**
   cumple tipos, enum y campos
3. **Adecuada**
   intent correcto; que la query conserve la necesidad lo mide Recall

Similitud

$$\cos(q, p) = q \cdot p \,/\, (\|q\|\|p\|)$$
$$\text{si } \|q\| = \|p\| = 1 \;\Rightarrow\; \cos = q \cdot p$$

- E5 con prefijos query: y passage:
- Vectores L2-normalizados, 384 dim., ≤ 512 tokens
- IndexFlatIP: búsqueda exacta contra todos los fragmentos

EXPERIMENTOS

Una variable por experimento

Experimento 1 · Consulta

basado en prompts

Cambia texto enviado al encoder: Q0 original vs Q1 del LLM

Fijo corpus, target_words 180, overlap_passages 1, E5, IndexFlatIP, k

Mide schema_valid_rate, intent_accuracy, Recall@1/3/5, rango de A y B

Si Q1 falla estricta: Recall = 0 · con respaldo: se usa Q0

Experimento 2 · Tamaño de fragmento

Cambia target_words = 100 / 180 / 320

Fijo corpus, Q0, qrels, overlap_passages 1, E5, L2, IP, IndexFlatIP, k

Mide Recall@1/3/5; principal: mean Recall@3

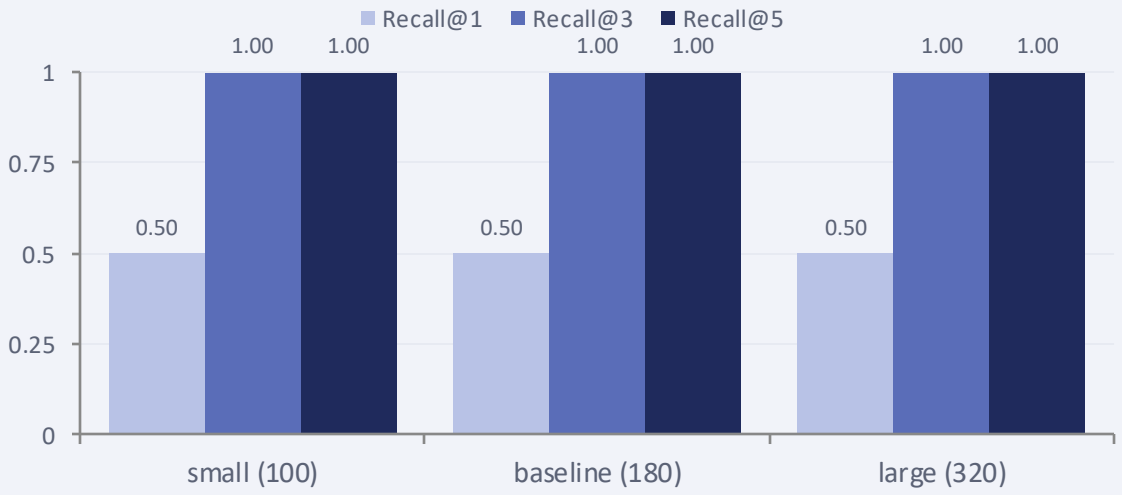
Qrels sobre passage_id: un artículo nunca se parte, la relevancia no cambia entre tamaños

Condición	target_words	Fragmentos	Por documento
small	100	49	4.9
baseline	180	20	2.0
large	320	11	1.1

RESULTADOS

Q0 recupera ambas normas; Q1 y el tamaño no ayudan

Exp. 2 · mean Recall@k por target_words (Q0)



Exp. 1 · Q0 vs Q1 (target_words 180)

	Q0	Q1 estricta	Q1 respaldo
schema_valid_rate	-	0.33	-
intent_accuracy	-	0.00	-
mean Recall@1	0.50	0.17	0.50
mean Recall@3	1.00	0.25	0.92
mean Recall@5	1.00	0.33	1.00

Error de recuperación · N3 con Q1 = “apela” (target_words 180)

La Norma A (D05-A06, 15 días hábiles) cae al puesto 4; entran salud (0.817) y transparencia (0.813). Los cinco primeros scores caben entre 0.811 y 0.827: con una palabra el encoder casi no distingue. No es granularidad: con Q0 y el mismo tamaño, las normas quedan 1.ª y 2.ª.

CIERRE

Limitación y conclusión

Limitaciones

- Efecto techo: Q0 ya llega a Recall@3 = 1.0; ningún experimento podía mostrar una mejora.
- 6 consultas y qrels del propio autor: una consulta mueve 16.7 puntos de Recall promedio.
- 4 de 6 JSON fallaron por una tilde (prohibición_permiso); normalizar tildes queda para otra iteración.
- Similitud alta no distingue contradicción de concordancia: decide el NLI, no el recuperador.

Conclusión

Con este corpus y E5-small, la pregunta original recupera las dos normas en el top-3 en las 6 consultas y con los tres tamaños.
Qwen 0.5B fue el punto débil: 2 de 6 JSON válidos, 0 intents correctos, y en N3 bajó Recall@3 de 1.0 a 0.5. Que el tamaño no cambie nada no prueba que no importe.